Étude de la catapulte incertaine (« statapulte »)

De la fiabilité de la mesure à la recherche d'une configuration cible

NORDIN – LAHOUSSE – HERVE – DOSSI – LANTZ

Décembre 2025

Table des matières

Introduction générale 4

1 Le système étudié : la catapulte incertaine 5
- 1.1 Paramètres de configuration et grandeur de sortie . . . 5
- 1.2 Modèle physique . . . 6
- 1.3 Sources de variabilité . . . 6
- 1.4 Problème direct et problème inverse . . . 6

2 Fiabilité du système de mesure : étude R&R 8
- 2.1 Modèle et collecte des données . . . 8
- 2.2 Analyse de variance (ANOVA) . . . 9

3 Modélisation de la portée par plans d'expériences 11
- 3.1 Principe général . . . 11
- 3.2 Plan complet 2^2 . . . 11
- 3.3 Plan complet 2^5 . . . 12
- 3.4 Plans fractionnaires . . . 13
  - 3.4.1 Premier plan fractionnaire 2^{5-2} . . . 13
  - 3.4.2 Second plan fractionnaire . . . 15
- 3.5 Plans de Taguchi . . . 16
  - 3.5.1 Principe . . . 16
  - 3.5.2 Plan L8 : 5 facteurs à 2 niveaux . . . 16
  - 3.5.3 Plan L25 : 5 facteurs à 5 niveaux . . . 17
- 3.6 Synthèse des plans d'expériences . . . 19

4 Atteinte d'une cible à partir du modèle de Taguchi 20
- 4.1 Objectif et démarche . . . 20
- 4.2 Modèle continu par interpolation . . . 20
- 4.3 Première démarche : minimisation de l'écart à la cible . . . 20
- 4.4 Seconde démarche : optimisation multicritère robuste . . . 21
- 4.5 Bilan des deux démarches . . . 22

5 Approche alternative : krigeage et algorithme génétique 24
- 5.1 Hypothèses du krigeage . . . 24
- 5.2 Données et matrice de distances . . . 24
- 5.3 Variogramme expérimental . . . 25
- 5.4 Variogramme théorique . . . 26
- 5.5 Système de krigeage ordinaire et validation . . . 27
- 5.6 Algorithme génétique . . . 27

6 Comparaison des deux approches inverses 29

Conclusion générale et perspectives 29

A Algorithme de Nelder–Mead 31
- A.1 Principe . . . 31
- A.2 Opérations sur le simplexe . . . 31
- A.3 Stratégie multi-start et filtrage . . . 32

A.4 Script Python 32

B Calcul du variogramme expérimental **37**
B.1 Variogramme sur une classe de distances 37
B.2 Variogramme sur l'ensemble des classes 37

Introduction générale

La recherche de la configuration d'un système mécanique qui produit une réponse donnée est un problème classique de l'ingénierie. Elle devient délicate lorsque le système est non linéaire et soumis à des incertitudes : une même configuration nominale ne produit alors jamais exactement la même sortie, et aucune relation analytique simple ne relie les entrées à la réponse.

Ce rapport traite ce problème sur un système simple mais représentatif : la **catapulte incertaine**, aussi appelée *statapulte*. Cinq paramètres de réglage (deux angles et trois positions) déterminent la portée du projectile, et plusieurs sources de variabilité (tolérances mécaniques, dispersion des masses, gestes de l'opérateur, etc.) perturbent chaque tir. L'objectif global est de **déterminer une configuration permettant d'atteindre une portée cible**, en garantissant la fiabilité des mesures, la qualité du modèle utilisé et la robustesse de la solution retenue.

La démarche suivie comporte quatre étapes :

1. **valider le système de mesure** par une étude de répétabilité et de reproductibilité (R&R) fondée sur une analyse de variance (section 2) ;
2. **modéliser la portée** en fonction des paramètres d'entrée à l'aide de plans d'expériences de complexité croissante : plans complets, fractionnaires et de Taguchi (section 3) ;
3. **résoudre le problème inverse** sur le modèle de Taguchi par l'algorithme de Nelder–Mead, puis valider expérimentalement les configurations obtenues (section 4) ;
4. **explorer une approche alternative** fondée sur un métamodèle de krigeage couplé à un algorithme génétique (section 5).

Les deux approches inverses sont comparées en section 6, avant une conclusion générale.

1 Le système étudié : la catapulte incertaine

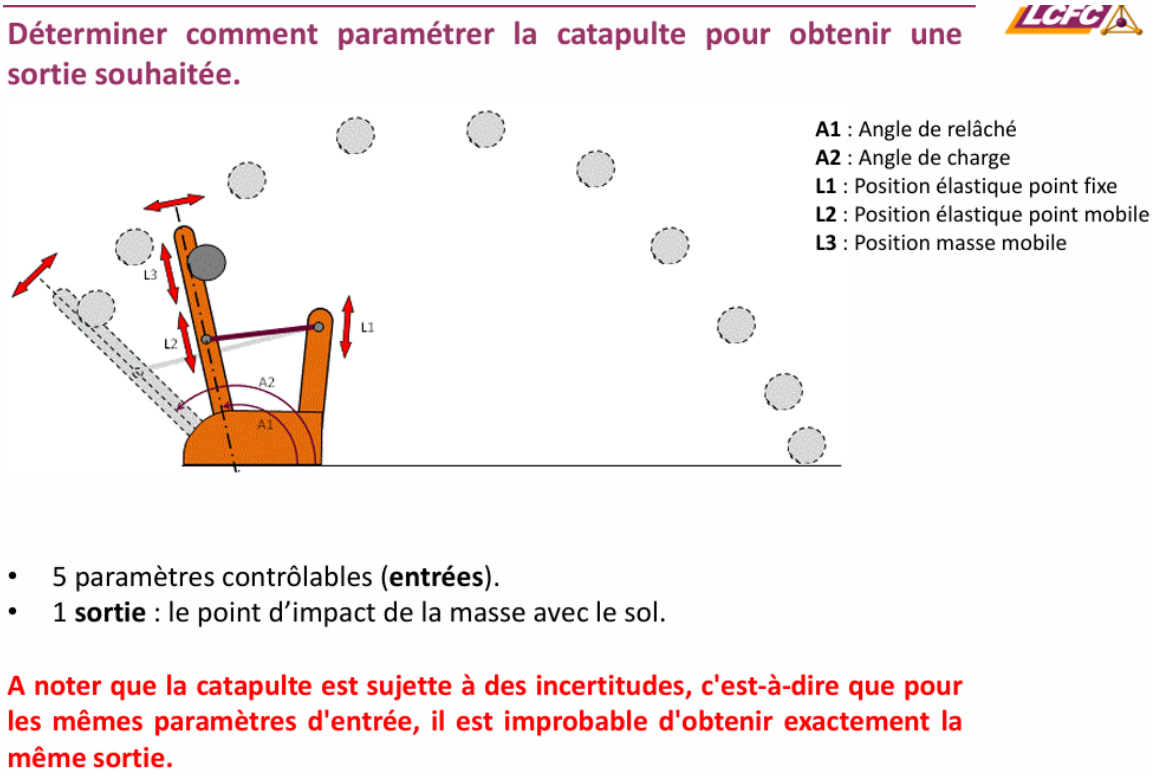


FIGURE 1 – Présentation de la catapulte et de ses cinq paramètres de réglage

1.1 Paramètres de configuration et grandeur de sortie

La catapulte projette une masse à l'aide d'un bras articulé actionné par un ressort élastique. Sa configuration est fixée avant chaque tir par cinq **facteurs contrôlables** :

— l'angle de butée A_1 (position du bras au relâchement), en degrés ;
— l'angle de charge A_2 (position du bras lors de la mise en tension), en degrés ;
— la position du point fixe du ressort L_1, en mètres ;
— la position du ressort sur le bras (point mobile) L_2, en mètres ;
— la position de la masse mobile sur le bras L_3, en mètres.

La masse du projectile, la raideur du ressort et l'accélération de la pesanteur sont des paramètres physiques constants dans le modèle nominal. La grandeur de sortie Y est la **portée horizontale** du projectile, mesurée au point d'impact avec le sol.

Les domaines de variation des facteurs diffèrent selon les études menées dans ce rapport. Ils sont regroupés dans le tableau 1.

TABLE 1 – Domaines de variation des facteurs selon les études

Étude	A_1 (°)	A_2 (°)	L_1 (m)	L_2 (m)	L_3 (m)
Plan complet 2^2	110 (fixe)	[130 ; 170]	0,145 (fixe)	0,13 (fixe)	[0,20 ; 0,30]
Plans 2^5, fractionnaires, Taguchi L8	[115 ; 135]	[155 ; 165]	[0,13 ; 0,145]	[0,13 ; 0,145]	[0,23 ; 0,245]
Taguchi L25 et optimisation	[90 ; 110]	[130 ; 180]	[0,14 ; 0,16]	[0,14 ; 0,16]	[0,24 ; 0,26]

1.2 Modèle physique

Le modèle repose sur une hypothèse de **conversion énergétique complète** : l'énergie potentielle élastique accumulée pendant la charge est intégralement transformée en énergie cinétique au moment du lâcher. Les frottements (air, pivots, dissipation interne) sont négligés afin de conserver un modèle simple et maîtrisable. À chaque tir, un jeu de paramètres « réels » est tiré aléatoirement autour des valeurs nominales, puis la trajectoire est calculée jusqu'à ce qu'elle recoupe le sol. Le système est donc :

- **numérique** : les calculs reposent sur un modèle informatique discret ;
- **déterministe conditionnellement** : pour un jeu de paramètres réels donné, la trajectoire est entièrement déterminée ;
- **stochastique au sens des entrées** : la variabilité des résultats provient uniquement des incertitudes sur les paramètres d'entrée.

Les résultats de tirs répétés forment ainsi un nuage de portées qui s'interprète statistiquement.

1.3 Sources de variabilité

Même avec une configuration identique, deux tirs peuvent différer en raison de variations non maîtrisées, appelées **sources de variabilité** :

- **mécaniques** : tolérances de montage (jeu, alignement), variation de la raideur du ressort k et de la masse du projectile m ;
- **liées à l'opérateur** : différences dans les angles de charge ou de relâchement, positionnement du projectile ou de la catapulte ;
- **environnementales** : température, humidité, frottements de l'air, gravité locale g ;
- **de mesure** : bruit ou erreur instrumentale du capteur de distance.

Dans le modèle fourni par Alain Etienne, ces sources sont quantifiées par des lois normales centrées sur les valeurs nominales (tableau 2).

TABLE 2 – Paramètres incertains et lois de variation utilisées dans le modèle

Paramètre	**Nom dans le code**	**Loi**	**Écart-type**	**Origine**
Angle de butée réel	`_angle_butee_reel`	$\mathcal{N}(A_1, \sigma_{\text{butée}})$	0,5°	Relâchement variable
Angle de charge réel	`_angle_charge_reel`	$\mathcal{N}(A_2, \sigma_{\text{charge}})$	0,5°	Mise en tension
Position ressort fixe	`_h_ressort_fixe_reel`	$\mathcal{N}(L_1, \sigma_{L_1})$	10^{-3} m	Tolérances mécaniques
Position ressort mobile	`_r_ressort_bras_reel`	$\mathcal{N}(L_2, \sigma_{L_2})$	10^{-3} m	Jeu mécanique
Position masse	`_r_masse_reel`	$\mathcal{N}(L_3, \sigma_{L_3})$	10^{-3} m	Positionnement
Raideur du ressort	`_raideur_elastique_reel`	$\mathcal{N}(k, \sigma_k)$	1,0 N/m	Vieillissement
Masse du projectile	`_masse_projectile_reel`	$\mathcal{N}(m, \sigma_m)$	$5 \cdot 10^{-4}$ kg	Fabrication
Gravité locale	`_g_reel`	$\mathcal{N}(g, \sigma_g)$	0,5 m/s^2	Réalisme

1.4 Problème direct et problème inverse

Le *problème direct* consiste à calculer la portée Y lorsque les paramètres $(A_1, A_2, L_1, L_2, L_3)$ sont connus. Le problème traité ici est le *problème inverse* : identifier les paramètres qui conduisent à une portée cible imposée. Ce problème est **mal posé** : plusieurs configurations peuvent produire la même portée, le système est non linéaire, et les incertitudes empêchent d'utiliser directement une relation déterministe. Sa résolution exige donc (i) des mesures fiables, (ii) un modèle de substitution de la réponse, rapide à évaluer, et (iii)

une méthode d'optimisation qui explore ce modèle. Les sections suivantes traitent ces trois points.

2 Fiabilité du système de mesure : étude R&R

Avant d'interpréter l'influence d'un paramètre, il faut s'assurer que le système de mesure n'est pas lui-même une source d'incertitude trop importante. La **répétabilité** mesure la dispersion des résultats quand un même opérateur répète la même mesure dans les mêmes conditions. La **reproductibilité** mesure les écarts entre plusieurs opérateurs qui effectuent la même mesure. Ensemble, elles indiquent quelle part de la variabilité revient au système de mesure plutôt qu'au procédé étudié.

2.1 Modèle et collecte des données

On réalise des mesures pour i configurations, j opérateurs et k répétitions. Le résultat $Y_{i,j,k}$ se décompose ainsi :

$$Y_{i,j,k} = \mu + \alpha_i + \beta_j + \delta_{i,j} + \varepsilon_{i,j,k}, \qquad \begin{cases} \mu = \mathbb{E}[Y] \\ \alpha_i : \text{effet principal de la configuration} \\ \beta_j : \text{effet principal de l'opérateur} \\ \delta_{i,j} : \text{interaction configuration/opérateur} \\ \varepsilon_{i,j,k} \sim \mathcal{N}(0, \sigma) : \text{erreur résiduelle} \end{cases}$$

La campagne comporte 3 configurations, 2 opérateurs et 5 mesures par couple, soit 30 mesures (tableau 3).

Table 3 – Portées mesurées (m) par opérateur et configuration

	Config. 1	**Config. 2**	**Config. 3**
Opérateur 1	0,8665	1,2201	2,1656
	0,8695	1,2027	2,1591
	0,8676	1,2186	2,1738
	0,8651	1,2070	2,1736
	0,8650	1,2051	2,1924
Opérateur 2	0,8639	1,2087	2,1963
	0,8644	1,2163	2,1706
	0,8747	1,2090	2,1925
	0,8649	1,2206	2,1812
	0,8640	1,2072	2,1495

TABLE 4 – Statistiques descriptives par configuration et par opérateur

	Config. 1	**Config. 2**	**Config. 3**	**Total**
Opérateur 1				
Somme	4,3337	6,0535	10,8645	21,2517
Moyenne	0,86674	1,2107	2,1729	1,41678
Variance	$3,533 \cdot 10^{-6}$	$6,4955 \cdot 10^{-5}$	$1,5632 \cdot 10^{-4}$	0,32746795
Opérateur 2				
Somme	4,3319	6,0618	10,8901	21,2838
Moyenne	0,86638	1,21236	2,17802	1,41892
Variance	$2,1787 \cdot 10^{-5}$	$3,3683 \cdot 10^{-5}$	$3,556 \cdot 10^{-4}$	0,33018898
Total (10 mesures par configuration)				
Somme	8,6656	12,1153	21,7546	–
Moyenne	0,86656	1,21153	2,17546	–
Variance	$1,1289 \cdot 10^{-5}$	$4,4605 \cdot 10^{-5}$	$2,348 \cdot 10^{-4}$	–

2.2 Analyse de variance (ANOVA)

L'ANOVA décompose la variabilité totale en contributions de l'opérateur, de la configuration, de leur interaction et de l'erreur résiduelle. Pour chaque source, on teste l'hypothèse nulle H_0 (« aucune différence significative entre les moyennes des groupes ») contre l'hypothèse alternative H_1 (« au moins une moyenne diffère »). La statistique de Fisher compare la variance inter-groupes à la variance intra-groupes :

$$F = \frac{\text{variance inter-groupes}}{\text{variance intra-groupes}}.$$

Une valeur de F proche de 1 indique l'absence d'effet. On rejette H_0 si $F_{\text{observé}} > F_{\text{critique}} = F_{1-\alpha}(ddl_1, ddl_2)$, avec un risque $\alpha = 5\,\%$, ce qui équivaut à une valeur $p < 0{,}05$.

TABLE 5 – Tableau d'analyse de la variance

Source	**Somme des carrés**	**ddl**	**Carré moyen**	$\boldsymbol{F}$	$\boldsymbol{p}$	$\boldsymbol{F}_{\text{crit}}$ **5 %**
Opérateurs	$3,4347 \cdot 10^{-5}$	1	$3,4347 \cdot 10^{-5}$	0,324	0,574	4,260
Configurations	9,20461519	2	4,60230759	43 426,5	$1,98 \cdot 10^{-43}$	3,403
Interaction	$3,8402 \cdot 10^{-5}$	2	$1,9201 \cdot 10^{-5}$	0,181	0,835	3,403
Résiduelle	0,0025435	24	$1,0598 \cdot 10^{-4}$	–	–	–
Total	**9,20723144**	**29**				

Interprétation.

- **Opérateurs** : F est faible et $p \gg 0{,}05$. Les opérateurs n'introduisent pas de différence significative, ce qui traduit une bonne **reproductibilité**.
- **Configurations** : F est très élevé et p quasi nul. Les changements de configuration ont un impact majeur sur la portée, ce qui est le comportement attendu d'une catapulte réglable.
- **Interaction** : elle est non significative ($p > 0{,}05$). Les opérateurs sont cohérents entre eux quelle que soit la configuration.

— **Résiduelle** : cette variabilité correspond aux fluctuations aléatoires non expliquées, c'est-à-dire à la **répétabilité** du système.

Répétabilité et reproductibilité.

$$\text{répétabilité} = \frac{SC_{\text{résiduelle}}}{SC_{\text{totale}}} = 2{,}76 \cdot 10^{-4} \;=\; 0{,}0276\,\%,$$

$$\text{reproductibilité} = \frac{SC_{\text{interaction}} + SC_{\text{opérateurs}}}{SC_{\text{totale}}} = 7{,}90 \cdot 10^{-6} \;=\; 7{,}90 \cdot 10^{-4}\,\%.$$

Ces deux contributions sont négligeables : plus de 99 % de la variabilité observée provient des changements de configuration. Le système de mesure est donc fiable, et les mesures peuvent servir à modéliser la portée en fonction des paramètres d'entrée.

3 Modélisation de la portée par plans d'expériences

Les plans d'expériences organisent les essais de manière à analyser l'influence simultanée de plusieurs facteurs sur une réponse tout en limitant le nombre d'essais. Ils permettent d'identifier les facteurs dominants, de quantifier leur contribution et de construire un modèle prédictif à moindre coût expérimental.

3.1 Principe général

Construction du modèle. Pour chaque essai i, les facteurs sont fixés à des valeurs $(L_1^i, L_2^i, L_3^i, A_1^i, A_2^i)$ et l'on mesure la portée Y_i (moyenne de 10 tirs dans le cas des plans complets). On cherche une approximation de la forme

$$Y \approx c_0 + c_1\,\phi_1 + c_2\,\phi_2 + \cdots + c_p\,\phi_p,$$

où les fonctions ϕ_k sont des termes simples (L_1, A_2), quadratiques (L_3^2) ou croisés (L_1L_2, A_1L_3). Chaque essai fournit une équation, et l'ensemble s'écrit sous forme matricielle $\mathbf{Y} = X\mathbf{c}$, où chaque ligne de X vaut $(1, \phi_1^i, \ldots, \phi_p^i)$. Le système est en général surdéterminé, et l'on retient la solution des moindres carrés :

$$\mathbf{c} = (X^{\mathrm{T}}X)^{-1}X^{\mathrm{T}}\mathbf{Y}.$$

Variables centrées réduites. Chaque facteur physique A prenant deux niveaux est codé dans $[-1, 1]$ par

$$x = \frac{A - A_0}{\text{Pas}},$$

où A_0 est le centre de l'intervalle et le pas sa demi-amplitude. Les coefficients obtenus dans cet espace sont directement comparables entre facteurs.

Effet principal. L'effet d'un facteur (ou d'une interaction) X_i est la différence entre la réponse moyenne au niveau haut et la réponse moyenne au niveau bas :

$$\text{Effet}(X_i) = \overline{Y \mid X_i = +1} - \overline{Y \mid X_i = -1}.$$

Cette grandeur ne dépend que des données et de la structure du plan (calculée sous Excel avec `MOYENNE.SI.ENS`). Grâce à l'orthogonalité des plans, elle est indépendante du modèle retenu, ce qui en fait la meilleure base de comparaison entre les différents plans.

3.2 Plan complet 2^2

Un premier plan complet ne fait varier que l'angle de charge A_2 et la position de la masse L_3 sur deux niveaux. Les autres facteurs restent fixés ($A_1 = 110°$, $L_1 = 0{,}145$ m, $L_2 = 0{,}13$ m).

Niveau	$A_2 \to x_1$	$L_3 \to x_2$
-1	130	0,2
$+1$	170	0,3

Essai	**Cste**	x_1	x_2	x_1x_2	Y (m)
1	1	-1	-1	$+1$	0,5292
2	1	$+1$	-1	-1	0,5629
3	1	-1	$+1$	-1	2,41327
4	1	$+1$	$+1$	$+1$	2,50046

TABLE 6 – Niveaux et plan factoriel complet 2^2 (chaque Y est la moyenne de 10 tirs)

La résolution au sens des moindres carrés donne, dans l'espace centré réduit :

$$\boxed{Y_{cr}(x_1, x_2) = 1{,}501 + 0{,}030\, x_1 + 0{,}955\, x_2 + 0{,}013\, x_1 x_2}$$

Le coefficient de x_2 est de l'ordre de 1, alors que ceux de x_1 et de $x_1 x_2$ sont de l'ordre de 10^{-2}. Dans cette configuration, la portée dépend donc bien plus de la position de la masse mobile que de l'angle de charge.

Avec $x_1 = (A_2 - 150)/20$ et $x_2 = (L_3 - 0{,}25)/0{,}05$, le modèle s'écrit dans l'espace physique :

$$\boxed{Y(A_2, L_3) = -3{,}0115 - 0{,}00175\, A_2 + 17{,}15\, L_3 + 0{,}013\, A_2 L_3}$$

Cette expression redonne exactement les quatre mesures du tableau 6.

Limites du plan 2^2.

- **Exploration restreinte** : seuls les quatre « coins » du domaine (A_2, L_3) sont testés. Le modèle est strictement local, et le centre du domaine reste inexploré.
- **Pas de courbure** : le modèle ne contient aucun terme quadratique. Il ne peut donc pas représenter un maximum, une saturation ou une zone d'insensibilité de la portée.
- **Modélisation incomplète** : trois des cinq facteurs sont figés, et leurs interactions éventuelles avec A_2 et L_3 restent invisibles.

Ce plan suffit pour un criblage grossier, mais il faut un plan plus riche pour caractériser la portée.

3.3 Plan complet 2^5

Le plan complet 2^5 fait varier les cinq facteurs sur deux niveaux (tableau 1), avec le codage $A_1 \to x_1$, $A_2 \to x_2$, $L_1 \to x_3$, $L_2 \to x_4$ et $L_3 \to x_5$. Il comporte 32 essais et permet d'estimer la constante, les 5 effets principaux et les 26 interactions. La méthode est la même que pour le plan 2^2, mais la matrice 32×32 n'est pas reproduite ici. Le coefficient de x_5 ($-0{,}685$) est de loin le plus important, et les effets simples dominent l'ensemble des coefficients (figure 2).

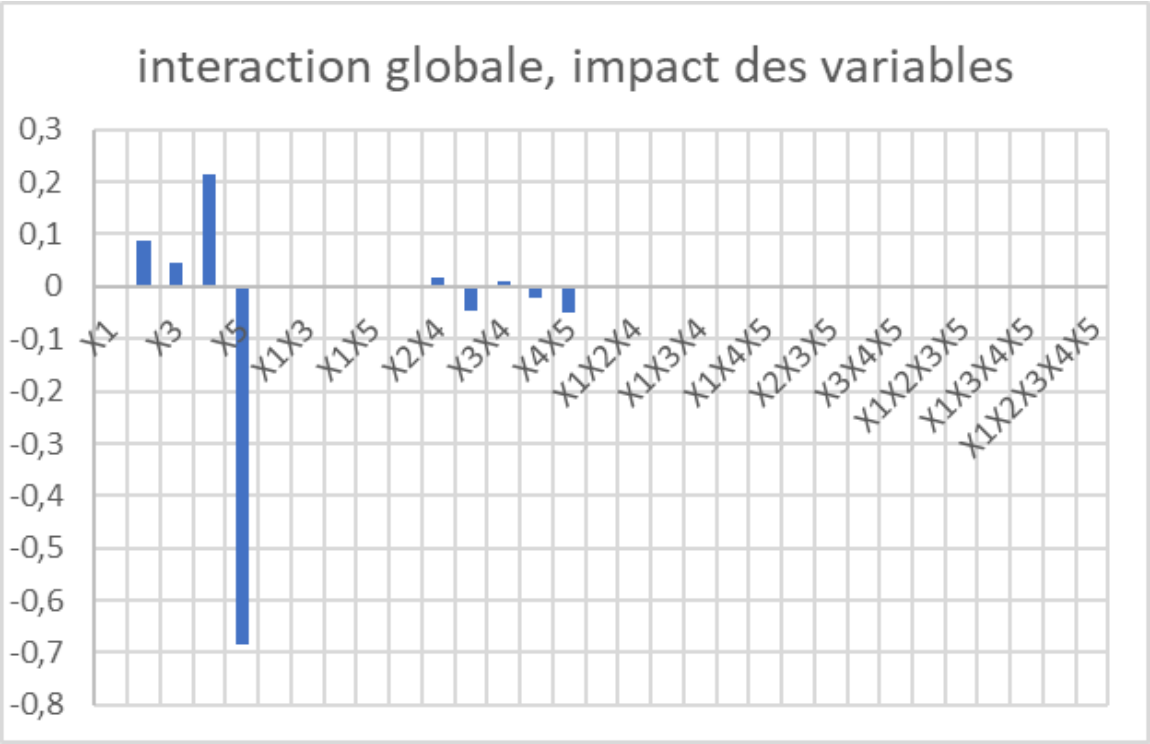


FIGURE 2 – Valeur des coefficients du plan 2^5 dans l'espace centré réduit

TABLE 7 – Plan 2^5 : effets décroissants (7 premiers termes)

Terme	X_5	X_4	X_2	X_4X_5	X_3	X_2X_5	X_3X_5
Effet	$-1{,}37$	0,426	0,176	$-0{,}0981$	0,0933	$-0{,}0911$	$-0{,}0405$
% de l'effet total	57,1	17,7	7,33	4,08	3,88	3,79	1,69
% cumulé	57,1	74,8	82,1	86,2	90,1	93,9	95,6

Les 7 premiers termes représentent plus de 95 % de l'effet total, et les 13 premiers plus de 99 %. Les 19 termes restants pèsent moins de 1 % de l'effet total, alors qu'ils mobilisent plus de la moitié des essais. Ce constat motive l'utilisation de plans réduits.

3.4 Plans fractionnaires

Un plan fractionnaire réduit le nombre d'essais en définissant certains facteurs à partir des autres par des **relations génératrices**. En contrepartie, certains effets deviennent indiscernables car ils correspondent aux mêmes combinaisons d'essais : ce sont des **alias**, déterminés par le calcul de Box.

3.4.1 Premier plan fractionnaire 2^{5-2}

On supprime le demi-plan inférieur de l'interaction d'ordre 5 $X_1X_2X_3X_4X_5$, puis celui de l'interaction d'ordre 4 $X_2X_3X_4X_5$. Le plan obtenu compte 8 essais au lieu de 32, et ses relations génératrices sont

$$X_1X_2X_3X_4X_5 = I \quad \text{et} \quad X_2X_3X_4X_5 = I.$$

Par exemple, la première relation donne $X_1X_2X_3 = X_4X_5$ (alias entre interactions d'ordre 3 et 2, ainsi qu'entre ordre 4 et effets simples), et la seconde donne $X_2X_3 = X_4X_5$ (alias entre interactions d'ordre 2). Le tableau 8 donne les groupes d'alias obtenus.

TABLE 8 – Groupes d'alias, plan 1

Groupe	**Termes confondus**
A	X_1, $X_2X_3X_4X_5$, $X_1X_2X_3X_4X_5$
B	X_2, X_1X_2, $X_3X_4X_5$, $X_1X_3X_4X_5$
C	X_3, X_1X_3, $X_2X_4X_5$, $X_1X_2X_4X_5$
D	X_4, X_1X_4, $X_2X_3X_5$, $X_1X_2X_3X_5$
E	X_5, X_1X_5, $X_2X_3X_4$, $X_1X_2X_3X_4$
F	X_2X_3, X_4X_5, $X_1X_2X_3$, $X_1X_4X_5$
G	X_2X_4, X_3X_5, $X_1X_2X_4$, $X_1X_3X_5$
H	X_2X_5, X_3X_4, $X_1X_2X_5$, $X_1X_3X_4$

TABLE 9 – Groupes d'alias, plan 2

Groupe	**Termes confondus**
A'	X_1, X_5, $X_2X_3X_4$, $X_1X_2X_3X_4X_5$
B'	X_2, $X_1X_2X_5$, $X_1X_3X_4$, $X_3X_4X_5$
C'	X_3, $X_1X_2X_4$, $X_1X_3X_5$, $X_2X_4X_5$
D'	X_4, $X_1X_2X_3$, $X_1X_4X_5$, $X_2X_3X_5$
E'	X_1X_2, X_2X_5, X_3X_4, $X_1X_3X_4X_5$
F'	X_1X_3, X_2X_4, X_3X_5, $X_1X_2X_4X_5$
G'	X_1X_4, X_2X_3, X_4X_5, $X_1X_2X_3X_5$
H'	X_1X_5, $X_1X_2X_3X_4$, $X_2X_3X_4X_5$

L'effet de chaque groupe se calcule comme pour un plan complet (tableau 10). Le groupe A, qui contient pourtant trois termes, n'est pas estimable avec les essais retenus et doit être écarté.

TABLE 10 – Premier plan fractionnaire : effets des groupes d'alias

Groupe	E	D	B	C	F	H	G
|effet|	1,3768	0,4217	0,1732	0,0905	0,0900	0,0697	0,0131
% effet	61,60	18,87	7,75	4,05	4,03	3,12	0,58
% cumulé	61,60	80,47	88,22	92,27	96,30	99,42	100

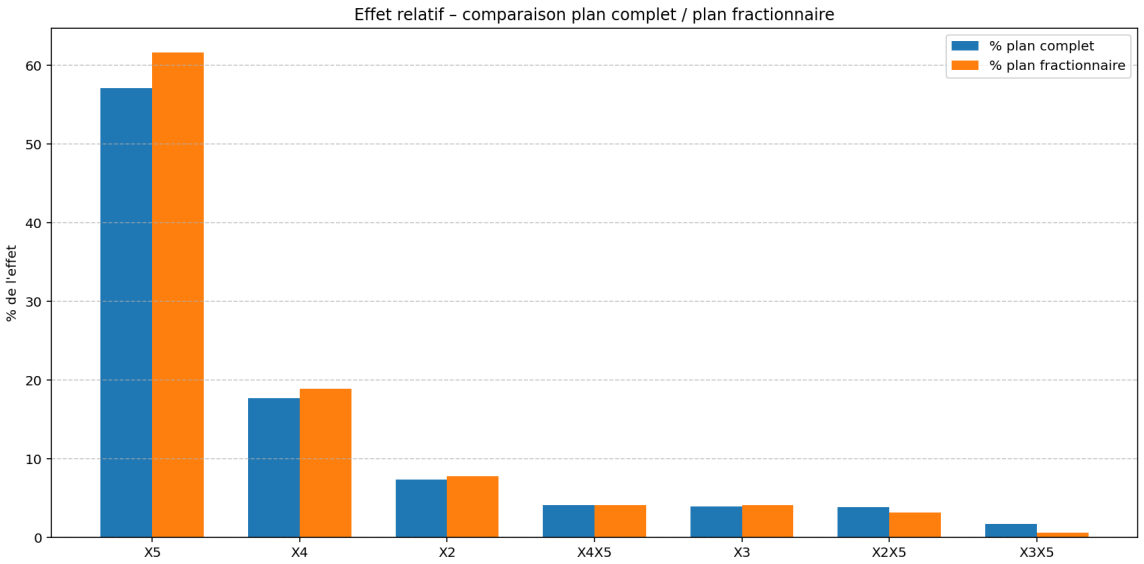


FIGURE 3 – Effets relatifs : plan complet (bleu) et groupe d'alias correspondant du premier plan fractionnaire (orange), pour les sept premiers termes

Les résultats sont proches de ceux du plan complet, alors que le nombre d'essais a été divisé par 4 (figure 3). Les trois premiers groupes, qui regroupent 12 termes, représentent

près de 90 % de l'effet. Le plan complet atteignait 90,1 % avec seulement 5 termes : le plan fractionnaire est donc moins précis, car des termes faibles se retrouvent dans des groupes importants.

Limites. La principale limite tient à la **mutualisation des effets**. Par exemple, X_3X_5 est le 7e terme le plus influent du plan complet (1,69 %), mais son groupe G ne pèse que 0,58 %. Deux termes importants d'effets opposés pourraient ainsi se compenser et être négligés à tort, sans que l'erreur soit visible. De plus, le groupe A n'a pas pu être estimé. Son effet réel est faible (0,16 %), mais comme les demi-plans ont été choisis arbitrairement, un groupe bien plus influent aurait pu devenir inestimable.

3.4.2 Second plan fractionnaire

En l'absence de méthode pour choisir le plan qui complète au mieux le premier, le second plan est construit lui aussi de manière arbitraire. On supprime les demi-plans inférieurs de $X_2X_3X_4X_5$ et de $X_1X_2X_3X_4$, ce qui donne les alias du tableau 9. Cette fois, c'est le groupe H' qui n'est pas estimable.

TABLE 11 – Second plan fractionnaire : effets des groupes d'alias

Groupe	A'	D'	B'	G'	C'	E'	F'
Effet	−1,37	0,421	0,172	−0,0893	0,0809	−0,0687	−0,0034
% |effet|	62,1	19,1	7,81	4,05	3,67	3,12	0,16
% cumulé	62,1	81,2	89,0	93,1	96,7	99,8	100

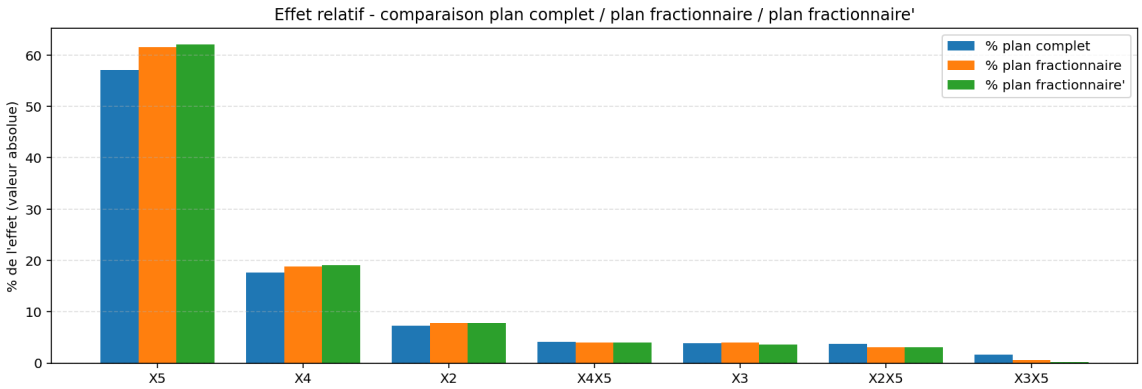


FIGURE 4 – Comparaison des effets relatifs principaux : plan complet et deux plans fractionnaires

Le second plan (en vert sur la figure 4) reste cohérent avec le plan complet et le premier plan fractionnaire. Supprimer des demi-plans d'ordre 4 et 5 n'a donc pas beaucoup dégradé l'information, malgré les risques évoqués ci-dessus. Le résultat d'un plan fractionnaire dépend toutefois du choix, ici arbitraire, des demi-plans supprimés. Pour être fiable, il faudrait multiplier les plans, ce qui ferait de nouveau augmenter le nombre d'essais.

3.5 Plans de Taguchi

3.5.1 Principe

Les plans de Taguchi reposent sur des **tableaux orthogonaux**. Chaque colonne y est statistiquement indépendante des autres, ce qui permet d'estimer séparément les effets principaux avec très peu d'essais. La méthode vise un système **robuste**, peu sensible aux sources de variabilité non contrôlées. Elle mesure cette robustesse par un *rapport signal/bruit* (S/N) qui combine la performance moyenne et la dispersion :

$$\underbrace{-10\log_{10}\Big(\tfrac{1}{n}\textstyle\sum_i y_i^{-2}\Big)}_{\text{Larger is Better}} \qquad \underbrace{-10\log_{10}\Big(\tfrac{1}{n}\textstyle\sum_i y_i^{2}\Big)}_{\text{Smaller is Better}} \qquad \underbrace{10\log_{10}\Big(\mu^2/\sigma^2\Big)}_{\text{Nominal is Best}}$$

Pour atteindre une cible, le critère adapté est *Nominal is Best*, où μ est la portée visée et σ l'écart-type des tirs. Dans les plans qui suivent, aucune cible n'est encore imposée : on cherche à maximiser la portée, avec le critère *Larger is Better*.

Construction. Le nombre d'essais T doit (1) être au moins égal au nombre de degrés de liberté du modèle,

$$ddl = 1 + \sum_{\text{facteurs et interactions}} (\text{nombre de niveaux} - 1),$$

et (2) être un multiple du PPCM des produits des nombres de niveaux des facteurs de chaque couple d'actions disjointes. Le plan est orthogonal si chaque colonne contient autant de fois chaque niveau et si toutes les colonnes sont distinctes.

3.5.2 Plan L8 : 5 facteurs à 2 niveaux

Avec 5 facteurs à 2 niveaux sans interaction, on obtient $ddl = 6$ et un PPCM de 4. Il faut donc $T = 8$ essais, contre 32 pour le plan complet 2^5.

Essai	X_1	X_2	X_3	X_4	X_5	Y (m)
1	1	1	1	1	1	0,65709
2	1	1	1	2	2	1,69497
3	1	2	2	1	1	0,47614
4	1	2	2	2	2	1,34846
5	2	1	2	1	2	2,10421
6	2	1	2	2	1	0,25860
7	2	2	1	1	2	1,94757
8	2	2	1	2	1	0,23207

Facteur	$\bar{Y}_{\text{niv. 1}}$	$\bar{Y}_{\text{niv. 2}}$	**Effet**
X_1	1,04466	1,13561	+0,0910
X_2	1,17872	1,00106	−0,1777
X_3	1,13243	1,04635	−0,0861
X_4	1,29625	0,88353	−0,4127
X_5	0,40548	1,77380	+1,3683

TABLE 12 – Plan de Taguchi L8 : essais (gauche), moyennes par niveau et effets principaux (droite)

Par ordre d'importance, on obtient $X_5 \gg X_4 > X_2 > X_1 \approx X_3$. Le facteur X_5 (L_3) domine largement, suivi de X_4 (L_2). Pour maximiser la portée, on retient pour chaque facteur le niveau de plus forte moyenne, soit $(X_1, X_2, X_3, X_4, X_5) = (2, 1, 1, 1, 2)$: L_3 au niveau haut et L_2 au niveau bas.

Le modèle linéaire dans l'espace centré réduit s'écrit

$$\hat{Y} = 1{,}0899 + 0{,}0457\,x_1 - 0{,}0888\,x_2 - 0{,}0430\,x_3 - 0{,}2064\,x_4 + 0{,}6839\,x_5,$$

avec $x_1 = \frac{A_1-125}{10}$, $x_2 = \frac{A_2-160}{5}$, $x_3 = \frac{L_1-0{,}1375}{0{,}0075}$, $x_4 = \frac{L_2-0{,}1375}{0{,}0075}$ et $x_5 = \frac{L_3-0{,}2375}{0{,}0075}$. Dans l'espace physique, il devient

$$\boxed{\hat{Y} \approx -13{,}72 + 0{,}00457\,A_1 - 0{,}0178\,A_2 - 5{,}74\,L_1 - 27{,}5\,L_2 + 91{,}2\,L_3}$$

3.5.3 Plan L25 : 5 facteurs à 5 niveaux

Pour couvrir un domaine plus large et capter des effets non linéaires, on construit un plan à 5 niveaux par facteur (tableau 13).

TABLE 13 – Niveaux du plan de Taguchi L25

Niveau	A_1 (°)	A_2 (°)	L_1 (m)	L_2 (m)	L_3 (m)
1	90	130	0,140	0,140	0,240
2	95	142,5	0,145	0,145	0,245
3	100	155	0,150	0,150	0,250
4	105	167,5	0,155	0,155	0,255
5	110	180	0,160	0,160	0,260

Pour les seuls effets principaux, $ddl = 1 + 5 \times 4 = 21$ et le PPCM vaut 25 : le tableau orthogonal est un $L_{25}(5^6)$ de 25 essais. Estimer en plus les interactions d'ordre 2 (10 interactions de 16 ddl chacune) porterait le nombre de ddl à 181 et le PPCM à 125, soit 250 essais. C'est beaucoup moins que les 3 125 essais d'un plan complet 5^5, mais nettement plus que les 25 essais disponibles : seuls les effets principaux sont donc estimés.

Modèle additif. Pour un essai défini par les niveaux (i, j, p, q, r) des facteurs $(A_1, A_2, L_1, L_2, L_3)$, la réponse prédite s'écrit

$$\widehat{Y} = m + a_{A_1}(i) + a_{A_2}(j) + a_{L_1}(p) + a_{L_2}(q) + a_{L_3}(r),$$

avec

$$a_F(\ell) = \overline{Y}_{F=\ell} - m,$$

où $m = \frac{1}{25}\sum_k Y_k$ est la moyenne globale et $\overline{Y}_{F=\ell}$ la moyenne des essais où le facteur F est au niveau ℓ. Par construction, $\sum_\ell a_F(\ell) = 0$. On obtient $m = 2{,}0955$ et les effets suivants (niveaux 1 à 5) :

$$\begin{aligned}
\mathbf{a}_{A_1} &= [-0{,}3163;\ -0{,}0390;\ \ 0{,}1841;\ \ 0{,}1907;\ -0{,}0195] \\
\mathbf{a}_{A_2} &= [-1{,}0654;\ -0{,}5458;\ \ 0{,}0304;\ \ 0{,}5878;\ \ 0{,}9930] \\
\mathbf{a}_{L_1} &= [\ \ 0{,}0929;\ -0{,}0478;\ \ 0{,}1260;\ -0{,}0947;\ -0{,}0763] \\
\mathbf{a}_{L_2} &= [-0{,}0289;\ \ 0{,}0337;\ -0{,}0732;\ \ 0{,}0577;\ \ 0{,}0107] \\
\mathbf{a}_{L_3} &= [\ \ 0{,}2648;\ \ 0{,}0764;\ -0{,}1445;\ -0{,}1523;\ -0{,}0443]
\end{aligned}$$

Contributions des facteurs. La contribution relative d'un facteur F à la variabilité totale vaut

$$P_F = \frac{SS_F}{SS_{\text{total}}} \times 100, \qquad SS_F = \sum_{\ell=1}^{5} n_\ell \big(\overline{Y}_{F=\ell} - \overline{Y}\big)^2, \qquad SS_{\text{total}} = \sum_{k=1}^{25} \big(Y_k - \overline{Y}\big)^2,$$

avec $n_\ell = 5$ essais par niveau.

TABLE 14 – Contribution relative des facteurs à la variabilité de la portée (plan L25)

Facteur	A_1	A_2	L_1	L_2	L_3
Contribution (%)	5,37	86,28	1,30	0,34	3,81

Sur ce domaine élargi, l'angle de charge A_2 explique à lui seul plus de 86 % de la variabilité, et l'effet de L_2 est négligeable. Ce classement diffère de celui du plan L8, car la plage de variation de A_2 est ici dix fois plus large.

Qualité du modèle. On évalue le modèle par le coefficient de détermination et l'erreur absolue moyenne :

$$R^2 = \frac{\sum_k (\widehat{Y}_k - \overline{Y})^2}{\sum_k (Y_k - \overline{Y})^2} = 0{,}97, \qquad \text{MAE} = \frac{1}{N} \sum_k |Y_k - \widehat{Y}_k| = 0{,}116 \text{ m}.$$

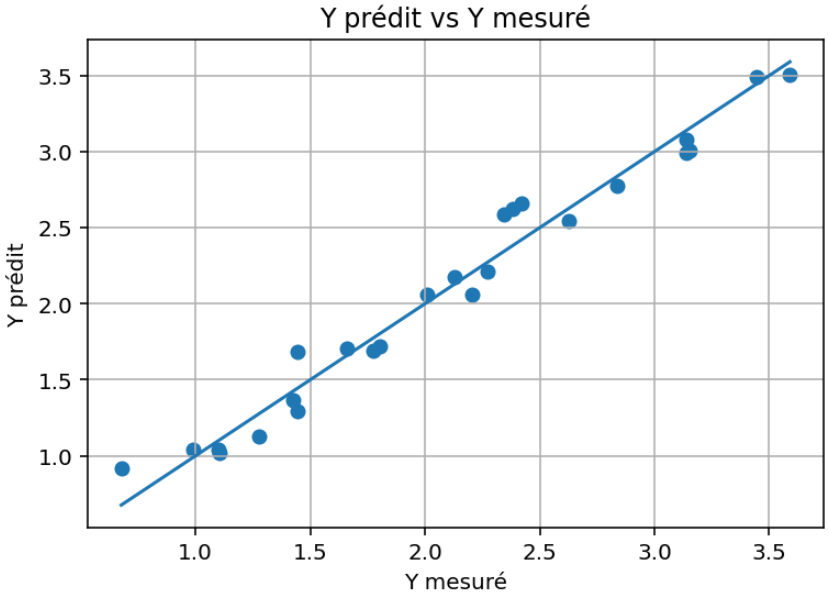


FIGURE 5 – Plan L25 : valeurs prédites et valeurs mesurées

Le modèle explique 97 % de la variance expérimentale, et son erreur moyenne représente environ 5 % de la portée moyenne. Le modèle additif décrit donc correctement le système dans le domaine étudié, et les interactions non modélisées n'y jouent qu'un rôle secondaire.

3.6 Synthèse des plans d'expériences

TABLE 15 – Comparaison des méthodes de plans d'expériences

Critère	**Plan complet 2^5**	**Plans fractionnaires**	**Plans de Taguchi**
Nombre d'essais	32	8 puis 8	8 (L8) / 25 (L25)
Calcul des effets	Moyennes conditionnelles	Effets de groupes d'alias	Moyennes par niveau
Facteur dominant	X_5 (L_3)	Groupe contenant X_5	X_5 (L8), A_2 (L25)
Classement des facteurs	Précis et exhaustif	Approximatif (alias)	Clair sur les effets principaux
Interactions identifiables	Toutes	Non (confusion)	Limitées
Modèle prédictif	Complet	Partiel, biais possible	Additif
Coût expérimental	Élevé	Faible	Très faible
Robustesse globale	Très élevée	Moyenne	Élevée

Le plan complet donne l'information la plus riche, mais son coût augmente très vite avec le nombre de facteurs. Les plans fractionnaires divisent ce coût, au prix de confusions d'effets dépendantes d'un choix arbitraire. Le plan de Taguchi L25 offre le meilleur compromis entre coût et qualité : 25 essais, un large domaine exploré, $R^2 = 0{,}97$. Il sert de base à la recherche de configuration de la section suivante.

4 Atteinte d'une cible à partir du modèle de Taguchi

4.1 Objectif et démarche

L'objectif est de trouver des configurations qui atteignent une **cible située à** $T = 1{,}95$ **m, à** $\Delta = 0{,}10$ **m près**. Aucune configuration du jeu de données expérimental disponible n'atteint cet objectif. On s'appuie donc sur le modèle de Taguchi L25 (section 3.5.3), retenu pour son faible coût expérimental, sa qualité ($R^2 = 0{,}97$) et le fait que la cible se trouve dans la plage des portées mesurées (0,68 à 3,59 m). La démarche est la suivante :

1. rendre continu le modèle discret ;
2. résoudre numériquement $\hat{Y} = T$;
3. vérifier expérimentalement les configurations obtenues.

4.2 Modèle continu par interpolation

Le modèle L25 n'est défini qu'aux niveaux expérimentaux. Comme le modèle suppose des effets principaux additifs, on interpole linéairement chaque effet entre deux niveaux consécutifs. Pour un facteur F et $x \in [x_k, x_{k+1}]$:

$$\tilde{a}_F(x) = a_F(k) + \frac{x - x_k}{x_{k+1} - x_k}\big[a_F(k+1) - a_F(k)\big],$$

d'où le modèle continu

$$\hat{Y}_c(A_1, A_2, L_1, L_2, L_3) = m + \tilde{a}_{A_1}(A_1) + \tilde{a}_{A_2}(A_2) + \tilde{a}_{L_1}(L_1) + \tilde{a}_{L_2}(L_2) + \tilde{a}_{L_3}(L_3).$$

$\hat{Y}_c$ est continue et affine par morceaux en chaque variable, mais elle n'est pas différentiable aux niveaux. On utilise donc une méthode d'optimisation sans gradient, l'algorithme de **Nelder–Mead**, avec démarrages multiples (multi-start) et filtrage des solutions trop proches. Son fonctionnement et le script sont détaillés en annexe A.

4.3 Première démarche : minimisation de l'écart à la cible

On minimise d'abord $(\hat{Y}_c - T)^2$ sur l'hyper-rectangle des niveaux. On obtient cinq solutions distinctes qui atteignent la cible à 10^{-4} près (tableau 16).

TABLE 16 – Première démarche : solutions numériques

Solution	A_1	A_2	L_1	L_2	L_3
1	92,14	152,84	0,1426	0,1415	0,2438
2	90,91	157,34	0,1451	0,1590	0,2463
3	108,25	144,72	0,1517	0,1420	0,2415
4	105,80	150,57	0,1598	0,1599	0,2596
5	108,30	151,29	0,1406	0,1446	0,2550

Le script de simulation ne permet pas de saisir exactement ces valeurs. Les essais de validation (25 tirs, 1 opérateur) portent donc sur les configurations réalisables les plus proches.

TABLE 17 – Première démarche : validation expérimentale (moyenne de 25 tirs)

Solution	$Y_{\text{prédit}}$ (m)	$Y_{\text{expérimental}}$ (m)	**Objectif respecté**
1	2,03	1,7705	Non
2	1,999	2,0430	Oui
3	2,01	1,4111	Non
4	1,98	2,3112	Non
5	2,0673	1,7982	Non

Une seule configuration (la n° 2) respecte l'objectif en moyenne, et 76 % de ses tirs tombent dans la tolérance. Les écarts viennent des limites du modèle additif utilisé entre les niveaux : il prédit une moyenne sans tenir compte de la dispersion ni des interactions non modélisées, qui peuvent dominer pour certaines combinaisons continues des paramètres. Une solution mathématiquement exacte n'est donc pas forcément robuste expérimentalement. Seules les configurations peu sensibles localement et proches du centre du domaine respectent effectivement l'objectif.

4.4 Seconde démarche : optimisation multicritère robuste

La seconde démarche ajoute à la seule exactitude des critères de **robustesse**, de **faisabilité** et de **respect de la tolérance**. Elle minimise un critère global formé de quatre termes :

— J_1 **: exactitude.** Ce terme garantit la proximité de la réponse prédite avec la cible :

$$J_1 = (\hat{Y} - T)^2.$$

— J_2 **: robustesse.** Ce terme mesure la sensibilité locale de la réponse, pondérée par les contributions w_k du tableau 14. Il favorise les configurations peu sensibles aux erreurs de réglage des facteurs dominants :

$$J_{2,w} = \sum_{k=1}^{5} w_k \left(\frac{\partial \hat{Y}}{\partial x_k} \right)^2 .$$

— J_3 **: faisabilité.** Ce terme pénalise les réglages proches des bornes et privilégie le cœur du domaine, plus facile à reproduire :

$$J_{3,w} = \sum_{k=1}^{5} w_k \left(\frac{x_k - x_{k,\text{milieu}}}{(x_{k,\max} - x_{k,\min})/2} \right)^2 .$$

— J_4 **: tolérance.** Ce terme est une contrainte souple qui écarte les solutions hors de la bande $[T - \Delta, T + \Delta]$, même si elles sont robustes :

$$J_4 = \max\big(0,\ |\hat{Y} - T| - \Delta\big)^2.$$

Le critère global s'écrit

$$\boxed{J = J_1 + \lambda\, J_{2,w} + \mu\, J_{3,w} + \nu\, J_4}, \qquad (\lambda, \mu, \nu) = (0{,}20\,;\ 0{,}05\,;\ 10).$$

Les poids sont choisis pour que les critères aient des contributions comparables autour des points candidats, afin qu'aucun ne domine par simple effet d'échelle. Le coefficient ν est volontairement élevé : toute sortie de la bande de tolérance devient alors rédhibitoire.

TABLE 18 – Seconde démarche : solutions candidates et valeurs des critères

Sol.	A_1	A_2	L_1	L_2	L_3	$Y_{\text{prédit}}$	J	J_1	J_2	J_3	J_4
1	95,80	153,31	0,1500	0,1500	0,2502	1,9526	1,99e-2	6,8e-6	9,60e-2	1,38e-2	0
2	106,05	152,56	0,1552	0,1449	0,2503	1,9538	2,09e-2	1,4e-5	9,60e-2	3,32e-2	0
3	110,00	156,67	0,1552	0,1500	0,2602	1,9698	4,72e-2	3,9e-4	1,91e-3	1,04e-1	0
4	93,95	144,31	0,1500	0,1449	0,2398	1,9592	5,17e-2	8,4e-5	2,06e-3	2,24e-1	0
5	108,97	154,76	0,1450	0,1602	0,2539	1,9511	6,21e-2	1,3e-6	9,59e-2	5,77	0

— **Solution 1** : meilleur compromis global (plus faible J), au centre du domaine et très proche de la cible.
— **Solution 2** : réponse prédite semblable, mais configuration plus excentrée, d'où une pénalité de centrage plus forte.
— **Solutions 3 et 4** : sensibilité réduite, mais proximité des bornes du domaine qui les rend moins robustes en pratique.
— **Solution 5** : excellente proximité de la cible, mais centrage très défavorable.

TABLE 19 – Seconde démarche : validation expérimentale (configurations réalisables les plus proches, 25 tirs, 1 opérateur)

Sol.	A_1	A_2	L_1	L_2	L_3	$Y_{\text{prédit}}$	$Y_{\text{exp.}}$	**Validation**
1	95,5	152	0,15	0,15	0,246	2,056	2,0382	Oui
2	106	152	0,155	0,14	0,246	2,0449	1,9544	Oui
3	110	156	0,155	0,15	0,256	1,8523	2,2292	Non
4	94	144,5	0,15	0,145	0,251	1,5611	1,6774	Non
5	108,5	153,5	0,145	0,16	0,251	1,9171	2,2374	Non

4.5 Bilan des deux démarches

La seconde démarche fournit deux configurations fonctionnelles, qui s'ajoutent à celle de la première démarche (tableau 20, figure 6).

TABLE 20 – Configurations atteignant la cible ($T = 1{,}95 \pm 0{,}10$ m)

	Configuration 1	**Configuration 2**	**Configuration 3**
$(A_1, A_2, L_1, L_2, L_3)$	(91,5 ; 157,5 ; 0,145 ; 0,16 ; 0,246)	(106 ; 152 ; 0,155 ; 0,14 ; 0,246)	(95,5 ; 152 ; 0,15 ; 0,15 ; 0,246)
Démarche	1	2	2
Tirs dans la tolérance	19/25 (76 %)	25/25 (100 %)	21/25 (84 %)

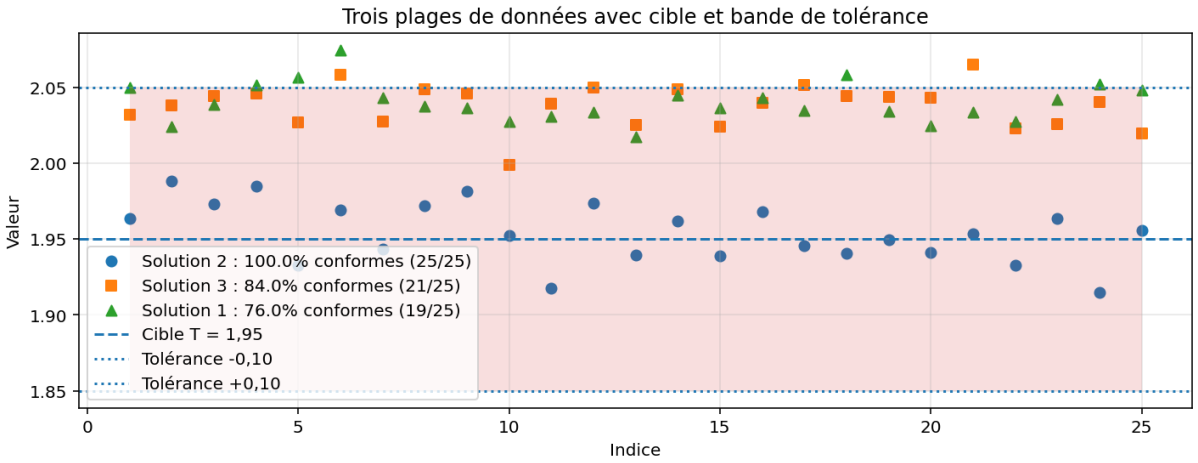


FIGURE 6 – Essais de validation des trois configurations retenues : la configuration 2 place 100 % de ses tirs dans la tolérance

L'objectif est atteint : la configuration 2 place tous ses tirs dans la bande de tolérance, avec une moyenne de 1,954 m pour une cible de 1,95 m. La seule proximité numérique avec la cible ne suffisait pas : c'est l'ajout de critères de robustesse et de centrage qui a fait passer le taux de réussite de 1 solution sur 5 à 2 sur 5. Au total, cette configuration a demandé 275 tirs expérimentaux : 25 pour le plan de Taguchi et $2 \times 5 \times 25 = 250$ pour les validations.

5 Approche alternative : krigeage et algorithme génétique

L'approche précédente repose sur un modèle additif qui ignore les interactions et sur un optimiseur local. On examine ici une autre voie. On construit d'abord un **métamodèle de krigeage** à partir de simulations numériques de la catapulte incertaine : ce modèle d'interpolation statistique fournit aussi une estimation de l'incertitude de chaque prédiction. On résout ensuite le problème inverse avec un **algorithme génétique**, méthode d'optimisation globale et stochastique adaptée aux problèmes non linéaires, multimodaux et bruités (figure 7).

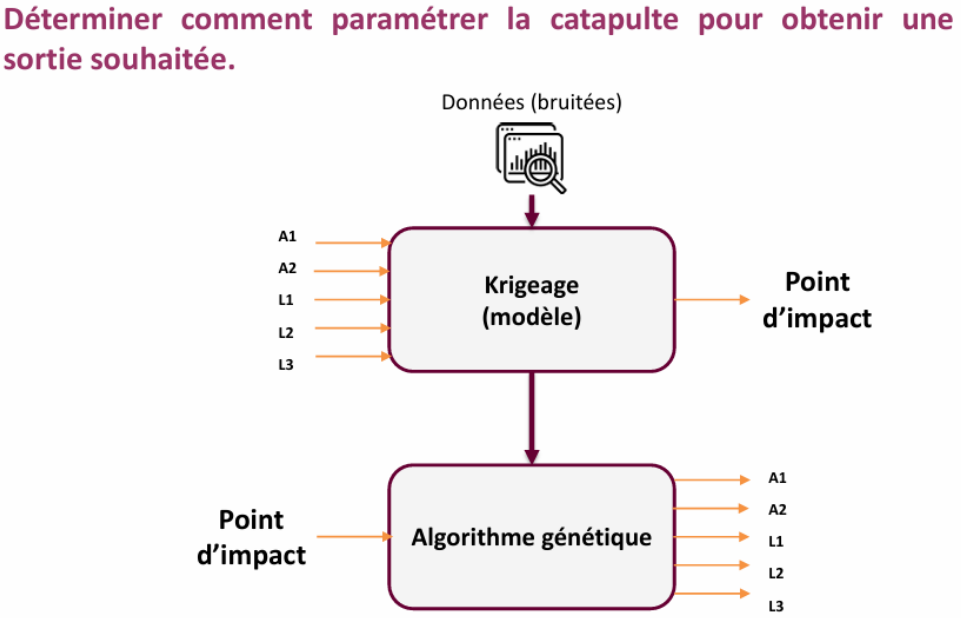


FIGURE 7 – Couplage krigeage – algorithme génétique

5.1 Hypothèses du krigeage

- **Stationnarité** : les paramètres varient dans des plages restreintes, et la réponse ne présente ni rupture brutale ni tendance globale dominante. L'hypothèse est donc acceptable localement, sans être garantie sur tout l'espace des paramètres.
- **Structure de corrélation** : deux configurations proches produisent des trajectoires et des portées proches. Cette corrélation forte entre points voisins est la condition essentielle des méthodes fondées sur une covariance.
- **Homogénéité** : le même modèle physique s'applique à toutes les simulations, et la dépendance entre entrées et sortie reste homogène sur le domaine.

5.2 Données et matrice de distances

Le jeu d'entraînement comprend 250 simulations et le jeu de test 100. Les données sont importées d'un fichier Excel avec `pandas` (fonction `importer_donnees`) : les cinq premières colonnes forment la matrice des entrées, et la dernière le vecteur des

portées. Chaque paramètre est ensuite normalisé indépendamment entre 0 et 10 par une mise à l'échelle Min–Max (`normaliser_donnees`), afin qu'aucun ne domine les calculs de distance. La transformation inverse permet de revenir à l'échelle physique. Enfin, `creer_matrice_distance` construit la matrice symétrique des distances euclidiennes entre toutes les configurations. Cette matrice sert à la fois au variogramme et au système de krigeage.

5.3 Variogramme expérimental

Le variogramme expérimental caractérise la dépendance spatiale entre observations. Pour une classe de distances $[h_{\min}, h_{\max}[$, il vaut

$$\gamma(h) = \frac{1}{2\,N(h)} \sum_{(i,j)\in\mathcal{P}(h)} (Z_i - Z_j)^2 ,$$

où $\mathcal{P}(h)$ est l'ensemble des $N(h)$ paires de points distincts dont la distance appartient à la classe. Les détails d'implémentation (exclusion de la diagonale, suppression des doublons, classes vides et centres de classes) sont donnés en annexe B.

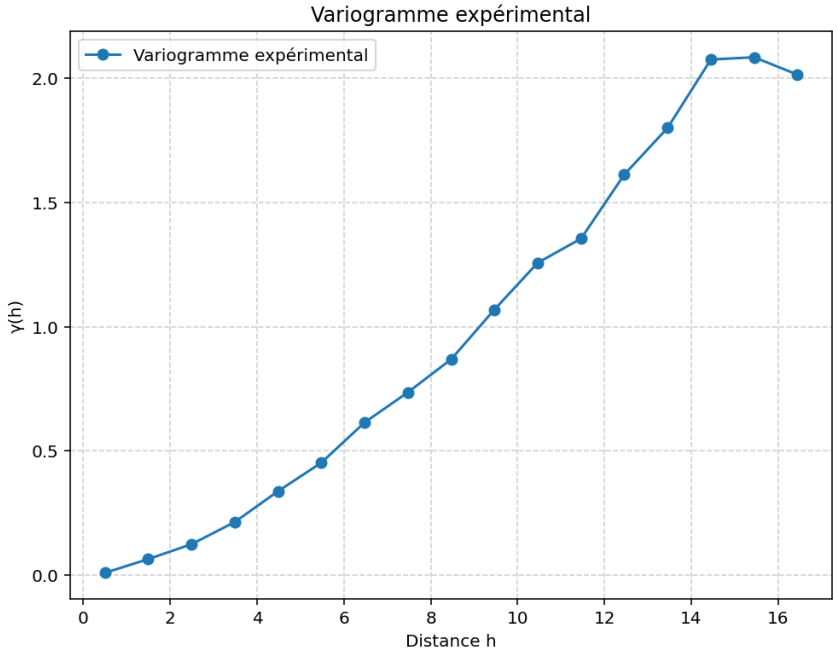


FIGURE 8 – Variogramme expérimental

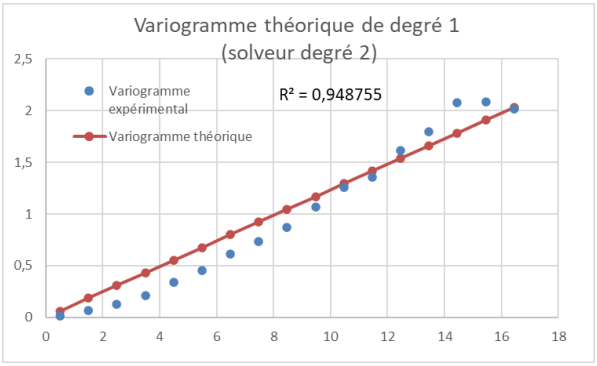
Le variogramme part d'une valeur proche de zéro, ce qui indique un faible effet de pépite et une bonne continuité locale. Il croît ensuite de façon progressive et quasi monotone, signe d'une corrélation significative entre points proches. Aux grandes distances, il tend vers un palier : au-delà de cette portée, les observations deviennent peu corrélées.

5.4 Variogramme théorique

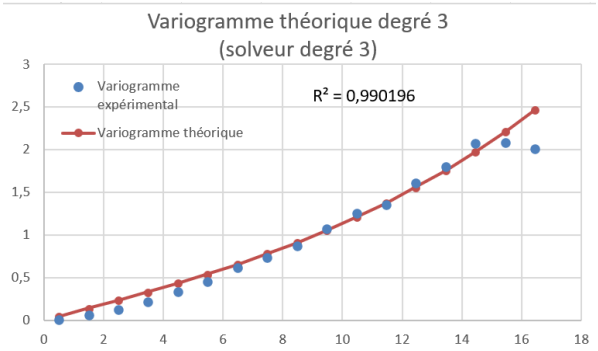
On cherche un modèle continu $\gamma_{\text{th}}(h;\boldsymbol{\theta})$ qui ajuste au mieux les points expérimentaux $(h_k, \gamma(h_k))$ au sens des moindres carrés non pondérés :

$$\min_{\boldsymbol{\theta}} \sum_k \left[\gamma(h_k) - \gamma_{\text{th}}(h_k;\boldsymbol{\theta})\right]^2 .$$

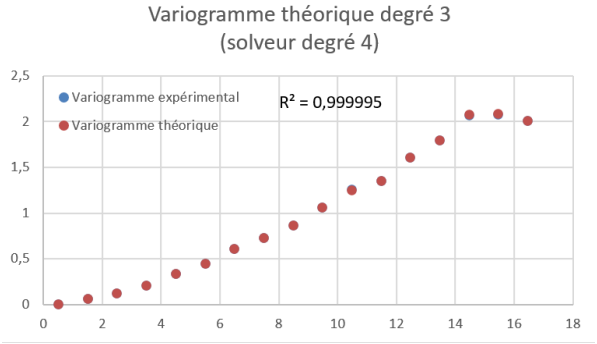
Le modèle doit être positif, globalement croissant et vérifier $\gamma(0) = 0$. On impose donc un terme constant nul à des polynômes de degré 2 à 5. Le problème étant non linéaire, il est résolu avec le solveur GRG d'Excel.



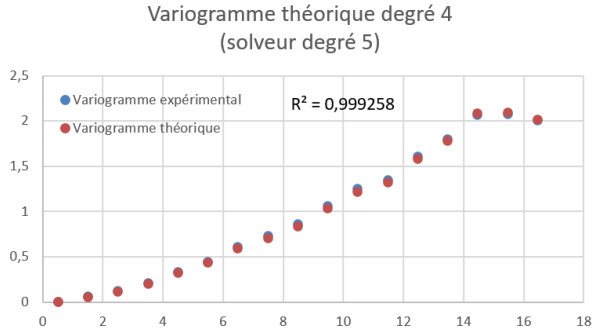
(a) Degré 2 : $a_1 = 0{,}123436$, $a_2 = 0$



(b) Degré 3 : $a_1 = 0{,}091894$, $a_2 = 0$, $a_3 = 0{,}000214$



(c) Degré 4 : $a_1 = 0{,}996284$, $a_2 = 0{,}000347$, $a_3 = 0{,}000816$, $a_4 = 0$



(d) Degré 5 : $a_1 = 0{,}962604$, $a_2 = 0{,}001026$, $a_3 = 0{,}00246$, $a_4 = 0{,}003528$, $a_5 = 0$

FIGURE 9 – Variogrammes théoriques ajustés par le solveur sous la contrainte $\gamma(0) = 0$ (le R^2 affiché est celui du modèle contraint)

Le coefficient du terme de plus haut degré s'annule souvent. Ce n'est pas une instabilité numérique : les données ne justifient pas un degré supplémentaire, et le solveur trouve naturellement un modèle de degré inférieur. L'ajustement de degré 4 est le plus satisfaisant, avec un R^2 très proche de 1. Il est retenu comme variogramme de référence :

$$\boxed{\gamma_{\text{th}}(h) = a_1 h + a_2 h^2 + a_3 h^3, \qquad a_1 = 0{,}996284,\ a_2 = 0{,}000347,\ a_3 = 0{,}000816}$$

5.5 Système de krigeage ordinaire et validation

$$\begin{bmatrix} \lambda_1 \\ \lambda_2 \\ . \\ . \\ \lambda_N \\ m \end{bmatrix} = \begin{bmatrix} \gamma(s_1 - s_1) & .. & \gamma(s_1 - s_N) & 1 \\ \gamma(s_2 - s_1) & .. & \gamma(s_2 - s_N) & 1 \\ . & .. & . & . \\ . & .. & . & . \\ \gamma(s_N - s_1) & .. & \gamma(s_N - s_N) & 1 \\ 1 & .. & 1 & 0 \end{bmatrix}^{-1} \begin{bmatrix} \gamma(s_0 - s_1) \\ \gamma(s_0 - s_2) \\ . \\ . \\ \gamma(s_0 - s_N) \\ 1 \end{bmatrix}$$

FIGURE 10 – Système matriciel du krigeage ordinaire

Les fonctions `inverse_matrice_krigeage_ordinaire` et `vecteur_variogramme` construisent les deux matrices du membre de droite. On en déduit le vecteur des poids $\boldsymbol{\lambda}$, qui inclut le multiplicateur de Lagrange, puis l'estimation et la variance de krigeage en tout point. Sur le jeu de test, on obtient $R^2 = 0{,}981$ et une variance d'estimation moyenne $\overline{\text{Var}} = 3{,}20$. Le métamodèle est jugé suffisamment fiable pour servir de fonction d'évaluation.

5.6 Algorithme génétique

L'algorithme génétique fait évoluer une population de solutions candidates (individus). La population initiale est tirée aléatoirement, puis chaque individu est évalué par une fonction de *fitness*. Les meilleurs individus sont sélectionnés, puis recombinés par croisement et perturbés par mutation. Le processus se répète jusqu'à un nombre maximal de générations.

Encodage. Chaque individu est codé par 10 gènes entiers, ce qui facilite l'application des opérateurs génétiques. La fonction `first_pop` génère la population initiale. La fonction `decodage` convertit les gènes en cinq paramètres physiques continus, avec une option de normalisation pour l'évaluation par krigeage.

Fitness. Pour chaque individu décodé et normalisé, on construit le vecteur de variogramme, on calcule les poids de krigeage et on estime la portée Z_{est}. La matrice inverse du système n'est calculée qu'une seule fois. La fitness vaut $|Z_{\text{est}} - Z_{\text{cible}}|$ et doit être minimisée.

Opérateurs.

- **Sélection par tournoi** de taille 3 : on tire trois individus avec remise et l'on garde le meilleur, jusqu'à reconstituer la population. La pression de sélection reste contrôlée, ce qui limite la convergence prématurée.
- **Croisement uniforme** : les parents sont appariés deux à deux. Un masque binaire aléatoire attribue chaque gène à l'un des parents, ce qui produit deux enfants complémentaires.
- **Mutation par réinitialisation aléatoire** : pour chaque individu, un gène sur dix est tiré au hasard et remplacé par une valeur admissible.

À chaque génération, le meilleur individu (fitness minimale) est sauvegardé. À la fin, la meilleure solution globale est décodée, puis évaluée par krigeage avec sa variance.

Résultats. La valeur cible, tirée du jeu de test, est $Z_{\text{cible}} = 1{,}89$ (tableau 21).

TABLE 21 – Résultat de l'optimisation inverse par algorithme génétique couplé au krigeage

Grandeur	**Valeur**
Valeur cible Z_{cible}	1,89
Meilleure fitness $\lvert Z_{\text{est}} - Z_{\text{cible}} \rvert$	$1{,}06 \times 10^{-4}$
Gènes du meilleur individu	$[0, 4, 2, 9, 2, 9, 0, 8, 9, 5]$
Configuration $(A_1, A_2, L_1, L_2, L_3)$	(94,0; 169,0; 0,129; 0,108; 0,295)
Configuration normalisée	(1,0; 7,25; 2,9; 0,8; 9,4)
Estimation par krigeage Z_{est}	1,89011
Variance de krigeage	3,67

L'algorithme trouve une configuration dont la portée estimée coïncide avec la cible à 10^{-4} près. La variance de krigeage associée (3,67) est toutefois du même ordre que la variance moyenne sur le jeu de test : l'estimation reste incertaine.

6 Comparaison des deux approches inverses

TABLE 22 – Comparaison des deux approches de résolution du problème inverse

Critère	**Taguchi L25 + Nelder–Mead**	**Krigeage + algorithme génétique**
Données	25 essais d'un plan orthogonal	250 simulations (+ 100 pour le test)
Modèle	Additif par niveaux, interpolé linéairement, sans interactions	Interpolation statistique, interactions implicitement prises en compte
Qualité du modèle	$R^2 = 0{,}97$, MAE = 0,116 m	$R^2 = 0{,}981$ (jeu de test)
Incertitude de prédiction	Non fournie par le modèle	Variance de krigeage en tout point
Optimiseur	Local, sans gradient, multi-start	Global, stochastique
Prise en compte de la robustesse	Explicite (critères J_2, J_3, J_4)	Non (fitness = écart à la cible)
Cible	1,95 m ± 0,10 m	1,89 m
Validation	Expérimentale : 1 configuration à 100 % dans la tolérance	Estimation par le métamodèle uniquement

Les deux approches se complètent. La première, peu coûteuse en essais, a été validée expérimentalement, mais son modèle reste fruste : l'erreur moyenne du modèle (0,116 m) est du même ordre que la tolérance visée (0,10 m). Il a fallu des critères de robustesse pour compenser cette imprécision. La seconde repose sur un modèle plus fidèle, qui fournit en plus une mesure de l'incertitude de prédiction. Celle-ci n'est cependant pas exploitée dans la fitness, et la configuration trouvée n'a pas été vérifiée par de nouveaux tirs. Une approche combinant le métamodèle de krigeage et les critères de robustesse J_2 à J_4, complétée par un terme pénalisant la variance de krigeage, réunirait les avantages des deux.

Conclusion générale et perspectives

Ce travail a traité le réglage de la catapulte incertaine de bout en bout. L'étude R&R a d'abord montré que le système de mesure est fiable : répétabilité et reproductibilité représentent moins de 0,03 % de la variabilité, qui est due à plus de 99 % aux changements de configuration. Les plans d'expériences ont ensuite permis de hiérarchiser les facteurs et de modéliser la portée. Le plan complet est le plus informatif mais le plus coûteux. Les plans fractionnaires réduisent le coût au prix de confusions d'effets. Le plan de Taguchi L25 offre le meilleur compromis, avec $R^2 = 0{,}97$ en 25 essais. Sur ce modèle, une optimisation multicritère par Nelder–Mead a fourni une configuration qui place 100 % de ses tirs dans la tolérance d'une cible à 1,95 m. Enfin, le couplage krigeage – algorithme génétique propose une alternative plus précise sur le plan du modèle, qui reste à valider expérimentalement.

Limites et pistes d'amélioration.

- **Mesure** : augmenter le nombre d'opérateurs et de configurations dans l'étude R&R, étudier des facteurs non pris en compte (température, vieillissement du ressort, usure du bras), automatiser la mesure et suivre la dérive du capteur dans le temps.
- **Modèle de Taguchi** : le modèle néglige les interactions, et son interpolation linéaire n'est fiable qu'au voisinage des niveaux. Un plan complémentaire de surface de réponse (Doehlert, Box–Behnken) permettrait d'estimer les interactions et la courbure.
- **Optimisation sur le modèle de Taguchi** : la seconde démarche réussit pour 2 solutions sur 5. Une troisième démarche pourrait pénaliser l'éloignement aux points expérimentaux connus, où le modèle est le plus fiable.
- **Krigeage** : sa qualité dépend de la couverture de l'espace par les données d'apprentissage. La stationnarité n'est vérifiée que localement, et un variogramme polynomial ne garantit pas une covariance valide sur un domaine élargi.
- **Algorithme génétique** : il est sensible à ses réglages (taille de population, nombre de générations, mutation) et ne garantit pas l'optimum global.
- **Modèle physique** : l'absence de frottements et de pertes énergétiques limite la transposition des résultats à une catapulte réelle.

Cette étude illustre une démarche complète d'ingénierie expérimentale : valider la mesure, modéliser la réponse avec un coût d'essais maîtrisé, puis rechercher des solutions non seulement exactes mais aussi robustes.

A Algorithme de Nelder–Mead

A.1 Principe

Le domaine d'optimisation est l'hyper-rectangle $\mathcal{D} = \prod_{k=1}^{n} [x_k^{\min}, x_k^{\max}]$ des intervalles admissibles. L'algorithme de Nelder–Mead y fait évoluer un *simplexe*, structure géométrique locale à $n+1$ sommets dont chaque sommet est une solution candidate $\mathbf{x}_i$, associée à la valeur $J(\mathbf{x}_i)$. À chaque itération, le pire sommet est remplacé par un point construit à partir du centroïde des autres. Le simplexe se déplace et se déforme ainsi vers les zones favorables, sans aucun calcul de dérivée, et converge vers un minimum local.

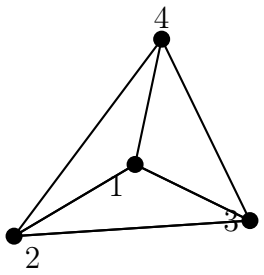


FIGURE 11 – Simplexe en dimension 3 : tétraèdre à quatre sommets

Un simplexe de dimension n est l'enveloppe convexe de $n+1$ points affinement indépendants : un segment en dimension 1, un triangle en dimension 2, un tétraèdre en dimension 3.

A.2 Opérations sur le simplexe

Les sommets sont triés de sorte que $J(\mathbf{x}_0) \leq \cdots \leq J(\mathbf{x}_n)$, et le centroïde des n meilleurs vaut $\mathbf{x}_c = \frac{1}{n} \sum_{i=0}^{n-1} \mathbf{x}_i$.

- **Réflexion** du pire sommet : $\mathbf{x}_r = \mathbf{x}_c + \alpha(\mathbf{x}_c - \mathbf{x}_n)$, avec $\alpha > 0$. Si $\mathbf{x}_r$ améliore la situation sans battre le meilleur sommet, il remplace $\mathbf{x}_n$.
- **Expansion** si $J(\mathbf{x}_r) < J(\mathbf{x}_0)$: $\mathbf{x}_e = \mathbf{x}_c + \gamma(\mathbf{x}_r - \mathbf{x}_c)$, avec $\gamma > 1$. On garde le meilleur de $\mathbf{x}_e$ et $\mathbf{x}_r$.
- **Contraction** si la réflexion échoue : $\mathbf{x}_{\text{contr}} = \mathbf{x}_c + \rho(\mathbf{x}_n - \mathbf{x}_c)$, avec $0 < \rho < 1$.
- **Réduction** si la contraction échoue aussi : $\mathbf{x}_i \leftarrow \mathbf{x}_0 + \sigma(\mathbf{x}_i - \mathbf{x}_0)$ pour tout $i \geq 1$, avec $0 < \sigma < 1$.

Gestion des bornes. Le simplexe n'est pas intrinsèquement contraint à rester dans $\mathcal{D}$. Une pénalité élevée est donc ajoutée à J pour tout point extérieur, qui est alors rejeté au classement. Près des frontières, le simplexe se « plaque » contre elles et se déplace tangentiellement.

Algorithm 1: Nelder–Mead pour la minimisation sans gradient

Input: fonction J, point initial $\mathbf{x}_0$, paramètres $(\alpha, \gamma, \rho, \sigma)$
Output: solution approchée $\mathbf{x}^\star$
Construire un simplexe initial de $n+1$ sommets autour de $\mathbf{x}_0$;
while *le critère d'arrêt n'est pas satisfait* **do**
  Évaluer et trier les sommets ; identifier $\mathbf{x}_{\text{best}}$ et $\mathbf{x}_{\text{worst}}$;
  Calculer le centroïde $\mathbf{x}_c$ des sommets hors $\mathbf{x}_{\text{worst}}$;
  $\mathbf{x}_r \leftarrow \mathbf{x}_c + \alpha(\mathbf{x}_c - \mathbf{x}_{\text{worst}})$;
  if $J(\mathbf{x}_r)$ *améliore la solution* **then**
    if $J(\mathbf{x}_r) < J(\mathbf{x}_{best})$ **then**
      $\mathbf{x}_e \leftarrow \mathbf{x}_c + \gamma(\mathbf{x}_r - \mathbf{x}_c)$; garder le meilleur de $\mathbf{x}_e$ et $\mathbf{x}_r$;
    else
      Remplacer $\mathbf{x}_{\text{worst}}$ par $\mathbf{x}_r$;
  else
    $\mathbf{x}_{\text{contr}} \leftarrow \mathbf{x}_c + \rho(\mathbf{x}_{\text{worst}} - \mathbf{x}_c)$;
    if *la contraction améliore la solution* **then**
      Remplacer $\mathbf{x}_{\text{worst}}$ par $\mathbf{x}_{\text{contr}}$;
    else
      Réduire tout le simplexe autour de $\mathbf{x}_{\text{best}}$;

A.3 Stratégie multi-start et filtrage

Nelder–Mead étant une méthode locale, sa convergence dépend du point de départ. L'algorithme est donc lancé depuis de nombreux points initiaux : quelques configurations centrales choisies a priori, complétées par des tirages uniformes dans $\mathcal{D}$. Deux filtres s'appliquent ensuite :

1. un **filtre fonctionnel**, qui ne conserve que les solutions dont la réponse prédite appartient à $[T - \Delta, T + \Delta]$;
2. un **filtre de distinction**, qui élimine les solutions trop proches d'une solution déjà retenue, selon une distance normalisée pondérée par les contributions de l'ANOVA.

On obtient ainsi un ensemble réduit de solutions réellement différentes du point de vue paramétrique.

A.4 Script Python

```python
import numpy as np

# ============================================================
# 1) Paramètres (cible + tolérance)
# ============================================================
m = 2.0955172
T = 1.95
DELTA = 0.10

# Poids ANOVA (% contributions)
P = np.array([5.372835878, 86.27543075, 1.297726059, 0.336195559, 3.805729944],
    dtype=float)
w = P / P.sum()  # poids normalisés (A1, A2, L1, L2, L3)
```

```python

# ============================================================
# 2) Niveaux physiques + effets Taguchi (a_F(1..5))
# ============================================================
A1_levels = np.array([90.0, 95.0, 100.0, 105.0, 110.0])
A2_levels = np.array([130.0, 142.5, 155.0, 167.5, 180.0])
L12_levels = np.array([0.14, 0.145, 0.15, 0.155, 0.16])
L3_levels  = np.array([0.24, 0.245, 0.25, 0.255, 0.26])

a_A1 = np.array([-0.3163072, -0.0389872,  0.1841268,  0.1907008, -0.0195332])
a_A2 = np.array([-1.0653932, -0.5458252,  0.0304308,  0.5877608,  0.9930268])
a_L1 = np.array([ 0.0928588, -0.0478212,  0.1260368, -0.0947372, -0.0763372])
a_L2 = np.array([-0.0288652,  0.0336928, -0.0732232,  0.0577288,  0.0106668])
a_L3 = np.array([ 0.2647828,  0.0763748, -0.1445372, -0.1522792, -0.0443412])

# Bornes : [A1, A2, L1, L2, L3]
bounds = np.array([
    [A1_levels.min(), A1_levels.max()],
    [A2_levels.min(), A2_levels.max()],
    [L12_levels.min(), L12_levels.max()],
    [L12_levels.min(), L12_levels.max()],
    [L3_levels.min(),  L3_levels.max()],
], dtype=float)

# ============================================================
# 3) Interpolation linéaire des effets + modèle continu Y_hat
# ============================================================
def interp_effect(x, x_levels, a_levels):
    x = float(x)
    if x <= x_levels[0]:
        return float(a_levels[0])
    if x >= x_levels[-1]:
        return float(a_levels[-1])
    k = np.searchsorted(x_levels, x) - 1
    x0, x1 = x_levels[k], x_levels[k+1]
    a0, a1_ = a_levels[k], a_levels[k+1]
    t = (x - x0) / (x1 - x0)
    return float(a0 + t * (a1_ - a0))

def Y_hat(xvec):
    A1, A2, L1, L2, L3 = xvec
    return (
        m
        + interp_effect(A1, A1_levels, a_A1)
        + interp_effect(A2, A2_levels, a_A2)
        + interp_effect(L1, L12_levels, a_L1)
        + interp_effect(L2, L12_levels, a_L2)
        + interp_effect(L3, L3_levels,  a_L3)
    )

# ============================================================
# 4) Critères J1, J2w, J3w, J4 + pénalité de bornes
# ============================================================
def J1_target(xvec):
    e = Y_hat(xvec) - T
    return e * e

def grad_Y_hat_fd(xvec, h=None):
    """Gradient par différences finies centrées, avec pas adaptés aux échelles."""
```

```
    x = np.asarray(xvec, dtype=float)
    if h is None:
        h = 1e-2 * (bounds[:,1] - bounds[:,0])
        h[2:] = np.maximum(h[2:], 1e-5)
    g = np.zeros_like(x)
    for i in range(len(x)):
        xp = x.copy()
        xm = x.copy()
        xp[i] = np.clip(xp[i] + h[i], bounds[i,0], bounds[i,1])
        xm[i] = np.clip(xm[i] - h[i], bounds[i,0], bounds[i,1])
        denom = xp[i] - xm[i]
        g[i] = (Y_hat(xp) - Y_hat(xm)) / (denom + 1e-15)
    return g

def J2_weighted_sensitivity(xvec):
    g = grad_Y_hat_fd(xvec)
    return float(np.sum(w * (g**2)))

def J3_weighted_centering(xvec):
    x = np.asarray(xvec, dtype=float)
    mid = 0.5 * (bounds[:,0] + bounds[:,1])
    half_range = 0.5 * (bounds[:,1] - bounds[:,0])
    z = (x - mid) / (half_range + 1e-15)
    return float(np.sum(w * (z**2)))

def J4_tolerance(xvec):
    err = abs(Y_hat(xvec) - T)
    excess = max(0.0, err - DELTA)
    return excess * excess

def bound_penalty(xvec, lam=1e6):
    x = np.asarray(xvec, dtype=float)
    p = 0.0
    for i in range(len(x)):
        lo, hi = bounds[i]
        if x[i] < lo:
            p += (lo - x[i])**2
        elif x[i] > hi:
            p += (x[i] - hi)**2
    return lam * p

LAMBDA = 0.20  # importance robustesse
MU     = 0.05  # importance "loin des bords"
NU     = 10.0  # importance "respect bande ±DELTA"

def J_total(xvec):
    return (
        J1_target(xvec)
        + LAMBDA * J2_weighted_sensitivity(xvec)
        + MU     * J3_weighted_centering(xvec)
        + NU     * J4_tolerance(xvec)
        + bound_penalty(xvec)
    )

# ============================================================
# 5) Nelder-Mead
# ============================================================
def nelder_mead(f, x0, step, max_iter=4000, tol=1e-12,
                alpha=1.0, gamma=2.0, rho=0.5, sigma=0.5):
```

```
    x0 = np.array(x0, dtype=float)
    n = x0.size
    step = np.array(step if np.iterable(step) else [step] * n, dtype=float)

    simplex = [x0]
    for i in range(n):
        xi = x0.copy()
        xi[i] += step[i]
        simplex.append(xi)
    simplex = np.array(simplex)
    fvals = np.array([f(x) for x in simplex])

    for it in range(max_iter):
        idx = np.argsort(fvals)
        simplex, fvals = simplex[idx], fvals[idx]
        if np.std(fvals) < tol:
            break
        x_best = simplex[0]
        x_worst = simplex[-1]
        centroid = np.mean(simplex[:-1], axis=0)

        # Réflexion
        x_r = centroid + alpha * (centroid - x_worst)
        f_r = f(x_r)
        if fvals[0] <= f_r < fvals[-2]:
            simplex[-1], fvals[-1] = x_r, f_r
            continue
        # Expansion
        if f_r < fvals[0]:
            x_e = centroid + gamma * (x_r - centroid)
            f_e = f(x_e)
            if f_e < f_r:
                simplex[-1], fvals[-1] = x_e, f_e
            else:
                simplex[-1], fvals[-1] = x_r, f_r
            continue
        # Contraction
        x_c = centroid + rho * (x_worst - centroid)
        f_c = f(x_c)
        if f_c < fvals[-1]:
            simplex[-1], fvals[-1] = x_c, f_c
            continue
        # Réduction
        for i in range(1, n + 1):
            simplex[i] = x_best + sigma * (simplex[i] - x_best)
            fvals[i] = f(simplex[i])

    best_idx = np.argmin(fvals)
    return simplex[best_idx], fvals[best_idx], it + 1

# ============================================================
# 6) Multi-start + filtrage des solutions distinctes
# ============================================================
def normalize(x):
    x = np.asarray(x, dtype=float)
    return (x - bounds[:,0]) / (bounds[:,1] - bounds[:,0] + 1e-15)

def weighted_weights(w, alpha=0.5):
    wp = w**alpha
```

```
    return wp / wp.sum()

w_dist = weighted_weights(w, alpha=0.5)

def weighted_distance(x, y):
    xn = normalize(x)
    yn = normalize(y)
    return float(np.sqrt(np.sum(w_dist * (xn - yn)**2)))

def is_distinct_weighted(x, sols, min_dist=0.08):
    for s in sols:
        if weighted_distance(x, s["x"]) < min_dist:
            return False
    return True

def random_start(rng):
    lo = bounds[:,0]
    hi = bounds[:,1]
    return lo + rng.random(5) * (hi - lo)

def find_multiple_solutions(n_starts=600, min_dist=0.08, seed=1):
    rng = np.random.default_rng(seed)
    step = np.array([2.0, 5.0, 0.002, 0.002, 0.002])
    starts = [
        np.array([100.0, 155.0, 0.150, 0.150, 0.250]),
        np.array([95.0,  150.0, 0.145, 0.155, 0.245]),
        np.array([105.0, 150.0, 0.155, 0.145, 0.255]),
    ]
    for _ in range(max(0, n_starts - len(starts))):
        starts.append(random_start(rng))

    sols = []
    for x0 in starts:
        x_opt, Jopt, iters = nelder_mead(J_total, x0=x0, step=step)
        y = Y_hat(x_opt)
        err = y - T
        if abs(err) <= DELTA and is_distinct_weighted(x_opt, sols, min_dist=min_dist):
            sols.append({
                "x": x_opt, "Y": y, "err": err, "J": Jopt,
                "J1": J1_target(x_opt),
                "J2w": J2_weighted_sensitivity(x_opt),
                "J3w": J3_weighted_centering(x_opt),
                "J4": J4_tolerance(x_opt),
                "iters": iters
            })
    sols.sort(key=lambda d: d["J"])
    return sols

# ============================================================
# 7) Exécution
# ============================================================
solutions = find_multiple_solutions(n_starts=150, min_dist=0.20, seed=2)
print(f"Solutions distinctes trouvées dans ±{DELTA} autour de T={T}:
↪  {len(solutions)}\n")
for k, s in enumerate(solutions[:5], start=1):
    A1, A2, L1, L2, L3 = s["x"]
    print(f"--- Solution {k} ---")
    print(f"A1={A1:.6f}  A2={A2:.6f}  L1={L1:.6f}  L2={L2:.6f}  L3={L3:.6f}")
    print(f"Y_pred={s['Y']:.8f}  (Y-T)={s['err']:+.8f}")
```

```
    print(f"J={s['J']:.3e}  J1={s['J1']:.3e}  J2w={s['J2w']:.3e}  "
          f"J3w={s['J3w']:.3e}  J4={s['J4']:.3e}  iters={s['iters']}\n")
```

B Calcul du variogramme expérimental

B.1 Variogramme sur une classe de distances

```
def calculer_variogramme_intervalle(dist, Z, h_min, h_max):
    dist = np.asarray(dist, dtype=float)
    Z = np.asarray(Z, dtype=float)

    n = len(Z)
    somme = 0.0
    compteur = 0

    for i in range(n):
        for j in range(i + 1, n):
            if h_min <= dist[i, j] < h_max:
                somme += (Z[i] - Z[j]) ** 2
                compteur += 1

    if compteur == 0:
        return np.nan  # aucun couple dans l'intervalle

    return 0.5 * somme / compteur
```

La fonction parcourt les paires (i, j) avec $j > i$ et ne retient que celles dont la distance appartient à $[h_{\min}, h_{\max}[$. Elle cumule les différences quadratiques correspondantes, puis les normalise par le nombre de paires. Une classe vide renvoie `NaN` et non 0 : on distingue ainsi l'absence d'information d'une continuité parfaite, et la classe est ignorée automatiquement lors du tracé et de l'ajustement.

B.2 Variogramme sur l'ensemble des classes

```
def calculer_variogramme_experimental(dist, Z, h_pas, fraction_max):
    dist = np.asarray(dist, dtype=float)
    Z = np.asarray(Z, dtype=float)

    assert dist.shape[0] == dist.shape[1], "La matrice de distances doit être carrée"
    assert dist.shape[0] == len(Z), "dist et Z doivent être compatibles"
    assert h_pas > 0, "h_pas doit être strictement positif"

    # Distance max (on ignore la diagonale)
    dmax = np.max(dist[np.triu_indices_from(dist, k=1)])
    h_max = fraction_max * dmax

    # Bornes des intervalles : [0, h_pas), [h_pas, 2*h_pas), ...
    bornes = np.arange(0.0, h_max + h_pas, h_pas)

    gamma = []
    h_centres = []
    for k in range(len(bornes) - 1):
        h_min = bornes[k]
```

```
20          h_max = bornes[k + 1]
21          g = calculer_variogramme_intervalle(dist, Z, h_min, h_max)
22          gamma.append(g)
23          h_centres.append(0.5 * (h_min + h_max))
24
25      return np.array(h_centres), np.array(gamma)
```

— **Diagonale exclue** : la distance d'un point à lui-même est nulle et n'apporte aucune information sur la variabilité. La distance maximale est donc calculée sur les seules paires distinctes.
— **Doublons supprimés** : la matrice étant symétrique, seule sa partie triangulaire supérieure est parcourue, si bien que chaque paire n'est comptée qu'une fois.
— **Centres de classes** : chaque valeur de γ est rattachée au centre de sa classe, ce qui est la convention usuelle en géostatistique. Elle permet un tracé cohérent et l'ajustement d'un modèle continu.